

IA - Classification Challenge

Le but de ce challenge est de tester vos implémentations des K plus proches voisins sur un nouveau dataset anonymisé. Le challenge se déroule en 3 étapes :

- Un premier dataset nommé « data.txt » est disponible sur DVO. Celui-ci a une structure différente que le dataset Iris car il est constitué de 7 variables d'entrée et une variable qualitative en sortie. Il est composé de 4 classes (0, 1, 2 ou 3) et de 1012 exemples. Vous êtes libre de le couper en deux ensembles train/test afin d'entraîner, faire varier des paramètres de votre approche et de l'évaluer par la suite.
- vous recevrez un deuxième dataset nommé « preTest.txt » dans quelques jours. Celui-ci n'aura d'autre but que de permettre de tester votre modèle sur de nouvelles données et vous assurer que tout fonctionne. Vous serez libre d'en faire ce que vous voulez.
- Enfin, (et l'évaluation reposera principalement sur cette dernière partie), vous recevrez un troisième dataset nommé « finalTest.txt ». Celui-ci porte sur le même problème qu'à la première étape mais la variable à prédire n'est pas donnée (la dernière colonne). Vous devrez utiliser le modèle que vous avez élaboré afin de prédire la classe pour chaque exemple du fichier « finalTest.txt ». Vous devrez créer un fichier de sortie nommé de vos noms, groupe de tp et de l'extension « txt ».

Ce fichier de sortie contiendra chaque prédiction (une prédiction par ligne : 0,1,2 ou 3 suivie d'un retour à la ligne). Le langage de programmation utilisé n'a pas d'importance, seul le fichier de sortie doit respecter **strictement** ces consignes car votre fichier sera analysé automatiquement. Un exemple de fichier vous sera fourni ainsi que des programmes permettant de tester votre sortie « checkLabels.py ». Tout écart à ce format sera fortement pénalisé (**-5points**).

Vous devrez déposer votre fichier de sortie sur DVO dans un dépôt spécifique. Dans un autre dépôt, vous devrez également rendre votre code (le **code exact** qui a permis de générer ce même fichier de sortie ainsi que d'un mini-rapport au format **pdf** expliquant les choix utilisés dans votre k plus proche voisins. Ce rapport est un tableau de bord et doit refléter vos tests, vos idées et vos choix qui vous ont amenés à la version déposée. Le projet est à faire en binôme.

Le tout est à rendre au plus tard le **19 avril**.

Bon Courage!